Martin Raič 5.02

računski: pisni	2 kolokvija
teoretični: ustni	
projektna naloga	

1. Centralni limitni izrek

$$S_n \sim Bin(n, \tfrac{1}{2}) \qquad P(S_n = k) = \binom{n}{k} \cdot 2^{-n}$$

$$\frac{P(S_n = k+1)}{P(S_n = k)} = \frac{\binom{n}{k+1} 2^{-n}}{\binom{n}{k} 2^{-n}} = \frac{\cancel{n!}\,(n-k)!\,k!}{(k+1)!\,(n-k-1)!\,\cancel{n!}} = \frac{n-k}{k+1}$$

Naj bo n sod $n = 2m$

$P(S_n = k)$ je maksimalna pri $k = m$ DN

(gledamo razmerje $\frac{P(S_n = k+1)}{P(S_n = k)}$)

$d = 0, 1, \ldots$

$$\frac{P(S_{2m} = m+d)}{P(S_{2m} = m)} = \frac{P(S_{2m} = m+1)\, P(S_{2m} = m+2) \cdots P(S_{2m} = m+d)}{P(S_{2m} = m)\, P(S_{2m} = m+1) \cdots} =$$

$$= \frac{2m-m}{m+1} \cdot \frac{2m-m-1}{m+2} \cdots \frac{2m-m-d+1}{m+d} =$$

$$= \frac{m \cdot (m-1) \cdot (m-2) \cdots (m-d+1)}{(m+1) \cdot \cdots \cdots (m+d)} =$$

$$= \left(\frac{1}{1+\frac{1}{m}}\right)\left(\frac{1-\frac{1}{m}}{1+\frac{2}{m}}\right) \cdots \left(\frac{1-\frac{d-1}{m}}{1+\frac{d}{m}}\right) \approx$$

$$\approx e^{-\frac{1}{m} - \frac{2}{m} - \cdots - \frac{d-1}{m} - \frac{1}{m} - \frac{2}{m} \cdots - \frac{d}{m}} = e^{-\frac{d(d-1)}{2} - \frac{d(d+1)}{2}}$$

$$\ln(1+x) \approx x \qquad 1 + x \approx e^x \qquad = e^{-\frac{d^2}{m}}$$

To velja tudi za $d = -1, -2, \ldots$ zaradi sodosti

$|d| \ll m$: $P(S_{2m} = m+d) \approx P(S_{2m} = m) \cdot e^{-\frac{d^2}{m}}$

Izkaže se: $$\lim_{m \to \infty} \sum_{d=-\infty}^{\infty} \left| \frac{P(S_{2m} = m+d)}{P(S_{2m} = m)} - e^{-\frac{d^2}{m}} \right| = 0$$

Izkaže se: $\lim_{m\to\infty} \sum_{d=-\infty}^{\infty} \left| \frac{P(S_{2m}=m+d)}{P(S_{2m}=m)} - e^{-\frac{d^2}{m}} \right| = 0$

seštevek verjetnosti

$$\sum_{d=-\infty}^{\infty} \frac{P(S_{2m}=m+d)}{P(S_{2m}=m)} = \frac{1}{P(S_{2m}=m)} \approx \sum_{d=-\infty}^{\infty} e^{-\frac{d^2}{m}}$$

$$\approx \int_{-\infty}^{\infty} e^{-\frac{x^2}{m}}\,dx = \sqrt{m}\int_{-\infty}^{\infty} e^{-t^2}\,dt = \sqrt{m\pi}$$

$x = t\sqrt{m}$

$dx = \sqrt{m}\,dt$

$$\Rightarrow P(S_{2m}=m) \approx \frac{1}{\sqrt{m\pi}}$$

$$P(S_{2m}=m+d) \approx \frac{1}{\sqrt{m\pi}} e^{-\frac{d^2}{m}}$$

$d = k - m = k - \frac{n}{2}$:

$$\boxed{P(S_n=k) \approx \frac{1}{\sqrt{2\pi n}} e^{-\frac{2(k-\frac{n}{2})^2}{n}}}$$

De Moivreova lokalna formula

Izkaže se, da to velja tudi za lihe n

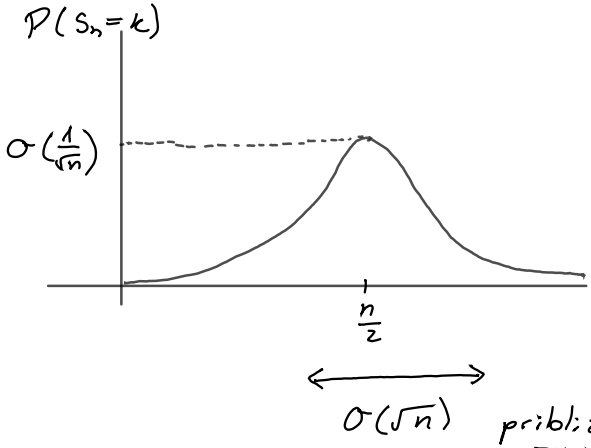

približna širina zvona

$$P(a \le S_n \le b) = \sum_{k=a}^{b} P(S_n=k) \approx \sqrt{\frac{2}{n\pi}} \sum_{k=a}^{b} e^{-\frac{2(k-\frac{n}{2})^2}{n}} \approx$$

$$\approx \sqrt{\frac{2}{n\pi}} \sum_{k=a}^{b} \int_{k-\frac{1}{2}}^{k+\frac{1}{2}} e^{-\frac{2(x-\frac{n}{2})^2}{n}} dx = \sqrt{\frac{2}{n\pi}} \int_{a-\frac{1}{2}}^{b+\frac{1}{2}} e^{-\frac{2(x-\frac{n}{2})^2}{n}} dx$$

$a, b \in \mathbb{Z} + \frac{1}{2} \quad a \le b$

$$P(a \le S_n \le b) = P(a < S_n < b) = P(a+\tfrac{1}{2} \le S_n \le b-\tfrac{1}{2}) =$$

$$= \sqrt{\frac{2}{n\pi}} \int_a^b e^{-\frac{2(x-\frac{n}{2})^2}{n}}$$

To velja tudi za splošna $a, b \in \mathbb{R}$ $a \le b$

Dobljeni približek za $P(S_n=k)$ je gostota porazdelitve $N(\frac{n}{2}, \frac{n}{4})$ v točki k.

pričakovana vrednost $\quad \sigma^2$ varianca

Podobno velja tudi za intervalske verjetnosti

Opazimo: $S \sim Bin(n,p)$ $E(S)=np$ $var(S)=np(1-p)$

Torej za $S \sim Bin(n, \frac{1}{2})$ velja $E(S)=\frac{n}{p}$ $var(S)=\frac{n}{4}$, torej enako kot za normalno porazdelitev

Binomska porazdelitev ko gre n proti neskončno je taka normalna porazdelitev, da ima isto pričakovano vrednost in varianco

Binomska porazdelitev $Bin(n,p)$
nastane kot porazdelitev vsote indikatorjev
$I_1 + \dots + I_n$ kjer so $I_1, \dots, I_n$ neodvisne
med sabo in $I_i \sim Be(p) = \begin{pmatrix} 0 & p \\ 1-p & 0 \end{pmatrix}$

Vsota veliko neodvisnih slučajnih spremenljivk z
Bernullijevo porazdelitvijo $Be(\frac{1}{2})$ je torej porazdeljena
približno normalno z ustrezno pričakovano
vrednostjo in varianco.

Primer na powerpointu
$X_1, \dots, X_n$ neodvisne. $\sim \begin{pmatrix} -1 & 0 & 9 \\ 0,5 & 0,45 & 0,05 \end{pmatrix}$

z vrjetnostjo
5% zadenemo
10 € (9 € profita)

$X_1, X_2, \dots, X_n$ neodvisne enakoporazdeljene
$E(X_1) = \mu_1 \quad E(X_1^2) < \infty \quad var(X_1) = \sigma_1^2 \quad \sigma_1 > 0$
Ce definiramo $S = X_1 + \dots + X_n$ se izkaže
$$P(a \leq S_n \leq b) \approx \frac{1}{\sigma_1 \sqrt{2\pi n}} \int_a^b e^{-\frac{(x - n\mu_1)^2}{2}} dx$$

$X_1, X_2, \dots, X_n$ neodvisne enakoporazdeljene

$E(X_1) = \mu_1 \quad E(X_1^2) < \infty \quad var(X_1) = \sigma_1^2 \quad \sigma_1 > 0$

Če definiramo $S = X_1 + \dots + X_n$ se izkaže

$$P(a \leq S_n \leq b) \approx \frac{1}{\sigma_1 \sqrt{2\pi n}} \int_a^b e^{-\frac{(x-n\mu_1)^2}{2n\sigma_1^2}} dx$$

Standardizacija: $\mathbb{E} \to 0 \quad var \to 1$

$$t = \frac{x - n\mu_1}{\sigma_1 \sqrt{n}} \qquad dt = \frac{dx}{\sigma_1 \sqrt{n}}$$

$$\frac{1}{\sqrt{2\pi}} \int_{\frac{a-n\mu_1}{\sigma_1\sqrt{n}}}^{\frac{b-n\mu_1}{\sigma_1\sqrt{n}}} e^{-\frac{t^2}{2}} dt = \Phi\left(\frac{b-n\mu_1}{\sigma_1\sqrt{n}}\right) - \Phi\left(\frac{a-n\mu_1}{\sigma_1\sqrt{n}}\right)$$

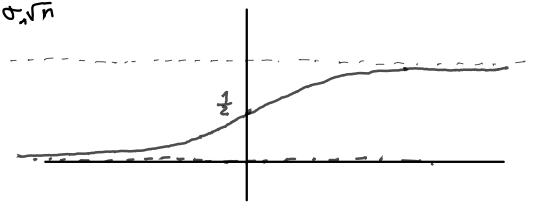

$$W_n := \frac{S_n - n\mu_1}{\sigma_1 \sqrt{n}} \qquad \mathbb{E}(W_n) = 0 \quad var(W_n) = 1$$

~ približno normalno porazdeljena

$$\Rightarrow P(a < S_n \leq b) = P\left(\frac{a-n\mu_1}{\sigma_1\sqrt{n}} \leq W_n \leq \frac{b-n\mu_1}{\sigma_1\sqrt{n}}\right) \approx$$

$$P(a \leq W_n \leq b) \approx \Phi(b) - \Phi(a) = P(a \leq Z \leq b)$$

$$Z \sim N(0,1)$$

Dogovor: $Z \sim N(0,1)$

Povsod kjer je $\leq$ je lahko tudi $<$

Izrek 1.1 (centralni limitni izrek; Paul Pierre Lévy)

Naj bo $X_1, X_2, \ldots$ NEP, $S_1, S_2, \ldots$ vsote X_i, $W_1, W_2, \ldots$

$$W_n = \frac{S_n - n\mu_1}{\sigma_1 \sqrt{n}}.$$

$$\lim_{n\to\infty} P(W_n \leq w) = \Phi(w)$$

Jarl Voldemar Lindeberg:

$$\lim_{n\to\infty} \sup_{w\in\mathbb{R}} \left| P(W_n < w) - \Phi(w) \right| = \lim_{n\to\infty} \left| P(S_n \leq x) - \Phi\left(\frac{x - n\mu_1}{\sigma_1\sqrt{n}}\right) \right| = 0$$

Dokaz: opustimo (Poglej v zapiskih, ne učit na pamet)

velja za vse dokaze, ki jih opuščamo

---

distribution

$$W_n \xrightarrow[n\to\infty]{d} N(0,1)$$

Izrek 1.2

Če so $W_1, W_2, \dots$ kot prej, za vsako zvezno funkcijo $h: \mathbb{R} \longrightarrow \mathbb{R}$, ki ima kvadratično omejeno rast ($\exists M \in \mathbb{R}. \forall x \in \mathbb{R}. |h(x)| \leq M(1+x^2)$) velja:

$$\lim_{n \to \infty} \mathbb{E}(h(W_n)) = \mathbb{E}(h(Z))$$

Dokaz opuščamo

$Y_1, \dots, Y_n$ neodvisne z vsoto S

$Z_1, \dots, Z_n$ neodvisne z vsoto T

zaenkrat ze n: trebada so normalne

Za $k = 1, \dots, n$ privzamemo

- $\mathbb{E}(|Y_k|^3), \mathbb{E}(|Z_k|^3) < \infty$
- $\mathbb{E}(Y_k) = \mathbb{E}(Z_k) = 0$
- $var(Y_k) = var(Z_k) = \sigma_k^2 \qquad \sigma_k \geq 0$

Tako je tudi $\mathbb{E}(S) = \mathbb{E}(T) = 0$ in

$$var(S) = Var(T) = \sigma^2 := \sum_{k=1}^{n} \sigma_k^2; \quad \sigma > 0$$

Trditev 1.3

Za poljubno slučajno spremenljivko Y z vrednostmi na $[0,\infty)$ in poljuben $p \geq 1$ velja $(E(Y))^p \leq E(Y^p)$

$$\left(p=2,\ Y=|X| \quad var(X) = E(X^2) - E(X)^2 \geq 0\right)$$

Dokaz: BŠZS: $p>1$, $P(Y>0)>0$, $E(Y^p)<\infty$

Podobna neenakost $E(Y) \leq a E(Y^p)$; $a>0$

$f(y) := ay^p - y$

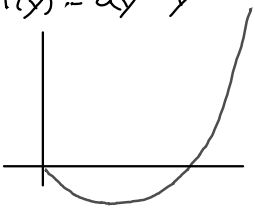

$f'(y) = apy^{p-1} - 1 = 0$

$\Rightarrow y = (ap)^{-\frac{1}{p-1}}$ minimum

$f(y) \geq f\left((ap)^{-\frac{1}{p-1}}\right)$

$ay^p - y \geq -\frac{p-1}{p}(ap)^{-\frac{1}{p-1}}$ (DN)

$$\Rightarrow E(Y) \leq aE(Y^p) + \frac{p-1}{p}(ap)^{-\frac{1}{p-1}} =: g(a)$$

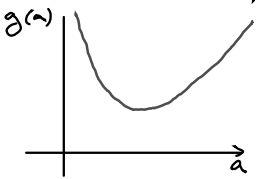

$g'(a) = E(Y^p) - ap^{-\frac{p}{p-1}}$ (DN)

$ap = E(Y^p))^{-\frac{p-1}{p}}$

$$\Rightarrow E(Y) \leq g\left(\tfrac{1}{p}E(Y^p)\right)^{-\frac{p-1}{p}} \underset{\text{DN}}{=} E(Y^p)^{\frac{1}{p}}$$

QED ■

$Y_1, \dots, Y_n$ neodv. z vsoto S $\quad E(Y_k) = E(Z_k) = 0$

$Z_1, \dots, Z_n$ neodv z vsoto T $\quad var(Y_k) = var(Z_k) = \sigma_k^2$

$h: \mathbb{R} \longrightarrow \mathbb{R}$

$$E(h(S)) - E(h(T))$$

Privzemimo, da je $h \in C^3(\mathbb{R})$ in $M_3 := \sup_{x \in \mathbb{R}} |h'''(x)| < \infty$

$$\left(\begin{array}{l} h(x) = h(0) + h'(0) + \frac{1}{2} h''(0)\, x^2 + \frac{1}{6} h'''(\xi) x^3 \\ \Rightarrow h \in \mathcal{O}(x^3) \end{array} \right)$$

$$T = V_0 \longrightarrow V_1 \longrightarrow V_2 \longrightarrow \dots \longrightarrow V_n = S$$

$$V_k = Y_1 + Y_2 + \dots + Y_k + Z_{k+1} + \dots Z_n$$

Privzemimo da so $Y_1, \dots Y_n$ in $Z_1, \dots Z_n$ vsi med seboj neodvisni.

$$E(h(S)) - E(h(T)) = \sum_{k=1}^{n} E(h(V_k)) - E(h(V_{k-1}))$$

$$U_k := Y_1 + \dots + Y_{k-1} + Z_{k+1} + \dots + Z_n$$

$U_k + Y_k = V_k \qquad U_k + Z_k = V_{k-1} \qquad U_k, V_k$ in Z_k so neodvisne

Pozor! Tu nastopata U in V

$$h(V_k) = h(U_k) + h'(U_k) Y_k + \frac{1}{2} h''(U_k) Y_k^2 + R_k; \quad |R_k| \leq \frac{1}{6} M_3 |Y_k|^3$$

$$h(V_{k-1}) = h(U_k) + h'(U_k) Z_k + \frac{1}{2} h'(U_k) Z_k^2 + \tilde{R}_k$$

T is supremum

$$|\tilde{R}_k| \leq \frac{1}{6} M_3 |Z_k|^3$$

$E(h'(U_k))E(Y_k) = 0$

$$E(h(V_k)) = E(h(U_k)) + E(h'(U_k) Y_k) + \dots + E(R_k)$$

$$E(h(V_{k-1})) = E(h(U_k)) + E(h'(U_k) Z_k) + \dots + E(\tilde{R}_k)$$

$E(h'(U_k))E(Z_k) = 0$

$$E(\tilde{R}_k) \leq \frac{1}{6} M_3 E(|Z_k|^3)$$

$$E(R_k) \leq \frac{1}{6} M_3 E(|Y_k|^3)$$

$$E(h(V_k)) - E(h(V_{k-1})) \leq \frac{1}{6} M_3 \left(E(|Y_k|^3) + E(|Z_k|^3) \right) \qquad / : \sum_{k=1}^{n}$$

$$E(h(S)) - E(h(T)) \leq \frac{1}{6} M_3 \sum_{k=1}^{n} \left(E(|Y_k|^3) + E(|Z_k|^3) \right)$$

((Iz prejšnje strani))

če $Z_k \sim N(0, \sigma_k^2) \Rightarrow T \sim N(0, \sigma^2)$ 27.2

$$Z_k \underset{\substack{\uparrow \\ \text{enako} \\ \text{porazdeljena}}}{\overset{d}{=}} \sigma_k Z \quad (\text{za } Z \sim N(0,1)) \Rightarrow E(|Z_k|^3) = \sigma_k^3 E(|Z|^3)$$

$$E(|Z|^3) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} |z|^3 e^{-\frac{z^2}{2}} dz \overset{DN}{=} \frac{4}{\sqrt{2\pi}}$$

$N(\mu, \sigma^2)(h) := E(h(X))$, kjer je $X \sim N(\mu, \sigma^2)$

Sledi: $|E(h(S)) - N(0,1)h| \leq \frac{1}{6} M_3 \sum (E(|Y_k|^3 + \frac{4}{\sqrt{2\pi}} \sigma_k^3)$

Po trditvi 1.3 je $\sigma_k^3 = \mathbb{E}(|Z_k|^2)^{\frac{3}{2}} =$

$= \mathbb{E}(|Y_k|^2)^{\frac{3}{2}} \leq \mathbb{E}(|Y_k|^3)$

Dokazali smo

Izrek 1.4

Naj bodo $Y_1, Y_2, \dots, Y_n$ neodvisne slučajne sprem. z $\mathbb{E}(|Y_k|^3) < \infty$ in $\mathbb{E}(Y_k) = 0$, $var(Y_k) = \sigma_k^2$

Naj bo $S = \sum_{k=1}^{n} Y_k$.

Tedaj za $\forall$ funkcijo $h \in \mathcal{C}^3(\mathbb{R})$ z $M_3 := \sup |h'''| < \infty$ velja:

$$\left| \mathbb{E}(h(S)) - N(0, \sigma^2)(h) \right| \leq \left(\frac{1}{6} + \frac{2}{3\sqrt{2\pi}} \right) M_3 \sum_{k=1}^{n} \mathbb{E}(|Y_k|^3),$$

kjer je $\sigma^2 = \sum_{k=1}^{n} \sigma_k^2$

Dokaz na prejšnji strani:

$\square$

Izrek 1.5 (Berry-Essenov izrek)

Obstaja taka univerzalna konstanta C, da za poljubne neodvisne slučajne spremenljivke $Y_1, \dots, Y_n$, ki izpolnjujejo pogoje prejšnjega izreka (z $\mathbb{E}(|Y_k|^3) < \infty$ in $\mathbb{E}(Y_k) = 0$, $\operatorname{var}(Y_k) = \sigma_k^2$, $S = \sum_{k=1}^{n} Y_k$) velja

$$\sup_{y \in \mathbb{R}} \left| \mathbb{P}(S \leq y) - \Phi\left(\frac{y}{\sigma}\right) \right| = \sup_{w \in \mathbb{R}} \left| \mathbb{P}\left(\frac{S}{\sigma} \leq w\right) - \Phi(w) \right|$$

$$\leq \frac{C}{\sigma^3} \sum_{k=1}^{n} \mathbb{E}(|Y_k|^3), \quad \text{če je } \sigma > 0$$

Dokaz opustimo (ni gg v zapiskih)

2013: $C = 0{,}5583$

za enako porazdeljene: $C = 0{,}47$

1956: spodnja meja: $\frac{\sqrt{10}+3}{6\sqrt{2\pi}} = 0{,}4097$

Naj bodo $X_1, X_2, \ldots$ neodvisne in enako porazdeljene

$\mathbb{E}(|X_1|^3) < \infty$, $\mathbb{E}(X_1) = \mu_1$, $var(X_1) = \sigma_1^2$ $(\sigma_1 > 0)$

$\mathbb{E}(|X_1 - \mu_1|^3) = \gamma_1^3$

$S_n := \sum_{k=1}^{n} X_k$ $\quad W_n := \frac{S_n - n\mu_1}{\sigma_1 \sqrt{n}}$, $\mathbb{E}(W_n) = 0$, $var(W_n) = 1$

$Y_k := X_k - \mu_1$, $E(Y_k) = 0$

Fiksiramo n $\quad S := \sum_{k=1}^{n} Y_k = S_n - n\mu_1 = W_n \sqrt{n}\, \sigma_1$

$\sigma^2 := var(S) = n\sigma_1^2$

$$\frac{1}{\sigma^3} \sum_{k=1}^{n} E(|Y_k|^3) = \frac{1}{n^{\frac{3}{2}} \sigma_1^3} n \gamma_1^3 = \frac{1}{\sqrt{n}} \left(\frac{\gamma_1}{\sigma_1} \right)^3 \xrightarrow[n \to \infty]{} 0$$

Hitrost konvergence: $\frac{1}{\sqrt{n}}$

Posledica 1.6

Če so $X_1, X_2, \ldots, S_n, W_n, \mu_1$ in γ_1 kot na prejšnji strani, velja:

$$\sup_{x \in \mathbb{R}} \left| P(S \leq x) - \Phi\left(\frac{x - n\mu_1}{\sigma_1 \sqrt{n}}\right) \right| = \sup_{w \in \mathbb{R}} \left| P(W_n \leq w) - \Phi(w) \right| \leq \frac{C}{\sqrt{n}} \left(\frac{\gamma_1}{\sigma_1}\right)^3$$

Dokaz na prejšnji strani

Posledica 1.7

$X_1, X_2, \dots, S_n, W_n, \mu_1, \sigma_1, \gamma_1$ kot na dveh straneh nazaj,

za vsako funkcijo $h \in C^3(\mathbb{R})$ z $M_3 := \sup |h'''| < \infty$

velja $\mathbb{E}(h(W_n)) - E(h(Z)) \leq \left(\frac{1}{6} + \frac{2}{3\sqrt{2\pi}}\right) \frac{M_3}{\sqrt{n}} \left(\frac{\gamma_1}{\sigma_1}\right)^3$

Če v izrek 1.4 vstavimo

$$\tilde{y}_k = \frac{X_k - \mu_1}{\sigma_1 \sqrt{n}}$$ dobimo

$\square$

2. Konvergenca porazdelitev

Definicija I: Zaporedje realnih slučajnih spremenljivk $X_1, X_2, \dots$ konvergira v porazdelitvi, k slučajni spremenljivki X, če za $\forall x \in \mathbb{R}$, za katerega je $\mathbb{P}(X=x)=0$ velja

$$\lim_{n\to\infty} \mathbb{P}(X_n < x) = \lim_{n\to\infty} \mathbb{P}(X_n \leq x) = \mathbb{P}(X < x).$$

Če je $X_1 \sim \mu_1, X_2 \sim \mu_2, \dots$ pišemo

$$X_n \xrightarrow[n\to\infty]{d} X$$

$$\mu_n \xrightarrow[n\to\infty]{d} \mu$$

namesto d lahko pišemo tudi w ali $\bar{s}$ (zaporedje porazdelitev šibko konvergira)

(konvergenca ki jo merijo z linearnimi funkcionali)

Opazka 2.1

Na ta način je, če so $X_n = c_n$ in $X = c$ kar konstantne, konvergenca v porazdelitvi ujema z običajno konvergenco zaporedij.

Naj bo $\lim_{n\to\infty} c_n = c$

$x<c$: za dovolj velike n je $c_n > x$

$\Rightarrow \mathbb{P}(X_n \leq x) = \mathbb{P}(X \leq x) = 0$

$x>c$: za dovolj velike n $c_n < x$

$\Rightarrow \mathbb{P}(X_n \leq x) = \mathbb{P}(X \leq x) = 1$

$x=c$: odvisno od tega na kakšen način konvergira c_n. kaotično obnašanje

DN: Dokaži še v obratno smer (če konvergira v porazdelitvi $\Rightarrow$ konvergira po točkah)

Opazka 2.2.

Velja $\lim_{n\to\infty} \mathbb{P}(X_n > x) = \lim_{n\to\infty} \mathbb{P}(X_n \geq x) = \mathbb{P}(X \geq x)$

Primer:

Če je $a_1, a_2, \ldots \in \mathbb{R}$ $\sigma_1, \sigma_2, \ldots \in [0,\infty)$
in $a = \lim_{n\to\infty} a_n$ $\sigma = \lim_{n\to\infty} \sigma_n$ gre

$$N(a_n, \sigma_n) \xrightarrow[n\to\infty]{d} N(a, \sigma^2)$$

Naj bo $\sigma > 0$. BŠZS: $\forall n \in \mathbb{N}$. $\sigma_n > 0$

$$\mathbb{P}(X_n \leq x) = \Phi\left(\frac{x-a_n}{\sigma_n}\right)$$

$$\downarrow d \quad \downarrow n \to \infty$$

$$\mathbb{P}(X < x) = \Phi\left(\frac{x-a}{\sigma}\right)$$

Izkaže se, da je to res tudi, če je $\sigma = 0$ (DN)

Imenitnejša formulacija CLI, natančneje izreka 2.1

Če so $X_1, X_2, \ldots$ neodvisne in enako porazdeljene z $\mathbb{E}(X_n) = \mu_1$ in $var(X_1) = \sigma_1^2$ ter $\sigma_1 > 0$ gre

$$\frac{X_1 + \ldots + X_n - n\mu_1}{\sigma_1 \sqrt{n}} \xrightarrow[n\to\infty]{d} N(0,1)$$

$\square$

Definicija: Slučajna spremenljivka na verjetnostnem prostoru $(\Omega, \mathcal{F}, P)$ in z vrednostmi v metričnem prostoru (M, d), je taka preslikava $X: \Omega \to M$, da če za vsako odprto množico $U \in M$ velja, da je $\{X \in U\}$ dogodek ($\{\omega \in \Omega;\ X(\omega) \in U\} \in \mathcal{F}$)

(M je lahko tudi samo topologija)

Opazka 2.3

Če je X slučajna spremenljivka z vrednostmi v metričnem prostoru (M, d) in $h: M \to \mathbb{R}$ zvezna funkcija, je tudi $h(X)$ slučajna spremenljivka. Za $\forall$ odprto množico $V \subseteq \mathbb{R}$ je namreč

$$\{h(X) \in V\} = \{X \in h^{-1}(V)\}$$

Definicija II: Zaporedje slučajnih spremenljivk $X_1, X_2, \ldots$ z vrednostmi v metričnem prostoru (M, d) v porazdelitvi konvergira proti X, če za $\forall$ zvezno in omejeno funkcijo $h: M \to \mathbb{R}$ velja, da je $\lim_{n \to \infty} E(h(X_n)) = E(h(X))$

$$\mathbb{P}(X_n=0) = 1-\frac{1}{n}$$
$$\mathbb{P}(X_n=n) = \frac{1}{n}$$

Primer: $X_n \sim \begin{pmatrix} 0 & n \\ 1-\frac{1}{n} & \frac{1}{n} \end{pmatrix}$

$$\mathbb{E}(h(X_n)) = h(0)\left(1-\frac{1}{n}\right) + h(n)\frac{1}{n}$$

Če je h omejena gre to proti $h(0)$

Zato gre $X_n \xrightarrow[n\to\infty]{d} 0$. Vendar pa je

$\mathbb{E}(X_n) = 1$, medtem ko je $\mathbb{E}(0) = 0$.

Izrek 2.4 (Eduard Helly, Hubbert Evelyn Gray)

Za $(M,d) = (\mathbb{R}, \text{obiščajna metrika})$ se definiciji I in II ujemata

---

Dokaz: Opustimo

Opazka 2.5

Porazdelitev poljubne realne slučajne spremenljivke je natanano določena že z vrjetnostmi $\mathbb{P}(X \leq x)$, kjer x preteče neko gosto podmnožico realne osi (npr $\{x;\ \mathbb{P}(X=x)=0\}$)

Podobno se za slučajno spremenljivko z vrednostmi v metričnem prostoru izkaže, da $\mathbb{E}(h(X))$, kjer h preteče omejene zvezne funkcije, natanano določa porazdelitev slučajne spremenljivke X; tj. vse možne vrjetnosti $\mathbb{P}(X \in B)$, kjer B preteče <u>Borellove množice</u>.

Posledica 2.6

Če gre $X_n \xrightarrow[n\to\infty]{d} X$ kot tudi $X_n \xrightarrow[n\to\infty]{} \tilde{X}$, mora biti $X \overset{d}{=} \tilde{X}$

enako porazdeljeni

(To nam pove da je ta topologija Hausdorffova)

Izrek 2.7 (portmanteau)

(portmanteau ang. – dvodelen kovček za plašče
portemanteau fra. – stojalo za plašče)

Za slučajne spremenljivke $X_1, X_2, \dots$ z vrednostmi v metričnem prostoru (M,d) so naslednje ekvivalentne:

1) $\Leftrightarrow$ $X_n \xrightarrow[n\to\infty]{d} X$ po definiciji II

2) $\Leftrightarrow$ za $\forall$ odprto množico $U \subseteq M$ velja
$$\liminf_{n\to\infty} \mathbb{P}(X_n \in U) \geq \mathbb{P}(X \in U)$$

3) $\Leftrightarrow$ za vsako zaprto množico $F \subseteq M$ velja
$$\limsup_{n\to\infty} \mathbb{P}(X_n \in F) \leq \mathbb{P}(X \in F)$$

Dokaz opuščamo

Opazka 2.8

Naj bo (M,d) metrični prostor in $\tilde{M} \subseteq M$.

Tedaj je $(\tilde{M},d)$ tudi metrični prostor in za dano preslikavo $\tilde{X}: \Omega \longrightarrow \tilde{M}$ je ekvivalentno, da je to slučajna spremenljivka z vrednostmi v $(\tilde{M},d)$ ali pa v (M,d).

To je res zato, ker velja $\tau(\tilde{M}) = \{U \cap \tilde{M};\ U \in \tau(M)\}$

topologija od $\tilde{M}$

Opazka 2.9

Če so $M, \tilde{M}, d$ kot prej in $\tilde{X}_1, \tilde{X}_2, \dots$ in X slučajne sprem. z vrednostmi v $(\tilde{M}, d)$, gre $\tilde{X}_n \to X$ v okviru $(\tilde{M}, d) \Leftrightarrow$ ko gre v okviru (M, d)

To sledi iz karakterizacije (2) v izreku portmanteau.

Opazka 2.10

naj bo (M, d) metrični prostor in $\tilde{M} \subseteq M$ odprta. Če so $X_1, X_2, \dots$ slučajne spremenljivke z vrednostmi v M, $\tilde{X}$ slučajna sprem. z vrednostmi v $\tilde{M}$ in gre $X_n \to \tilde{X}$ velja

$$\lim_{n \to \infty} \mathbb{P}(X_n \in \tilde{M}) = 1$$

Definicija: Naj bodo $X_1, X_2, \dots$ in X slučajne spremenljivke definirane na istem verjetnostnem prostoru in z vrednostmi v istem metričnem prostoru (M, d). Pravimo, da zaporedje $X_1, X_2, \dots$ konvergira proti X v verjetnosti, če za $\forall r > 0$. $\lim_{n\to\infty} \mathbb{P}(d(X_n, X) \geq r) = 0$

Pišemo: $X_n \xrightarrow[n\to\infty]{\mathbb{P}} X$

Opazka 2.11

$$X_n \xrightarrow[n\to\infty]{\mathbb{P}} X \iff d(X_n, X) \xrightarrow[n\to\infty]{\mathbb{P}} 0$$

$$d(X_n, X) = d_{\mathbb{R}}(d(X_n, X), 0)$$

Trditev 2.12.

Ko je $\lim_{n\to\infty} \mathbb{P}(X_n = \tilde{X}_n) = 1$, gre

$$d(X_n, \tilde{X}_n) \xrightarrow[n\to\infty]{\mathbb{P}} 0$$

Dokaz:

Predpostavka je ekvivalentna izjavi

$\lim_{n\to\infty} \mathbb{P}(X_n \neq \tilde{X}) = 0$. Tedaj pa tudi

za $\forall r > 0$. $\lim_{n\to\infty} \mathbb{P}(d(X_n, \tilde{X}_n) \geq r) = 0$

qed ■

Trditev 2.13

Naj bodo $X_1, X_2, \dots, \tilde{X}_1, \tilde{X}_2, \dots$ in X slučajne spremenljivke z vrednostmi v metričnem prostoru (M,d) in naj gre $d(X_n, \tilde{X}_n) \xrightarrow[n\to\infty]{\mathbb{P}} 0$.

Tedaj velja:

(1) Če gre $X_n \xrightarrow[n\to\infty]{\mathbb{P}} X$, gre tudi $\tilde{X}_n \xrightarrow[n\to\infty]{\mathbb{P}} X$

(2) Če gre $X_n \xrightarrow[n\to\infty]{d} X$, gre tudi $\tilde{X}_n \xrightarrow[n\to\infty]{d} X$

Dokaz opustimo

Trditev 2.14

Če gre $X_n \xrightarrow[n\to\infty]{\mathbb{P}} X$, gre tudi $X_n \xrightarrow{d} X$

Dokaz:

Po opazki 2.11 gre $d(X_n, X) \xrightarrow[n\to\infty]{\mathbb{P}} 0$.

Uporabimo trditev 2.13, kjer za X_n vzamemo X in za $\tilde{X}_n$ vzamemo X_n

$\blacksquare$

	$\tilde{X}=1$	$\tilde{X}=2$
$X=1$	0	$\frac{1}{2}$
$X=2$	$\frac{1}{2}$	0

Torej obrat trditve ne velja.

Trditev 2.15

Če gre $X_n \xrightarrow[n\to]{d} c$ ← konstanta, gre tudi $X_n \xrightarrow[n\to\infty]{\mathbb{P}} c$

(za konvergenco proti konstanti velja tolej ekvivalenca)

Dokaz: Za $r>0$ je $K(c,r) = \{x \in M ; d(x,c) < r\}$.

Po opazki 2.10 mora biti potem

$$\lim_{n\to\infty} \mathbb{P}(X_n \in K(c,r)) = 1$$

$$\Updownarrow$$

$$d(X_n, c) < r$$

qed ■

Posledica 2.16

Če je c konstanta, je $X_n \xrightarrow[r\to\infty]{d} c$

$$\Leftrightarrow d(X_n, c) \xrightarrow[n\to\infty]{\mathbb{P}} 0 \Leftrightarrow d(X_n, c) = \xrightarrow[n\to\infty]{d} 0$$

Dokaz: □

Trditev 2.17 (neenačba Markova)

Za nenegativno slučajno spremenljivko W in poljuben $a>0$ velja: $\mathbb{P}(W \geq a) \leq \frac{E(W)}{a}$

Dokaz:

Rezultat sledi iz neenakosti

$$\mathbb{1}(W>a) \leq \frac{W}{a}$$

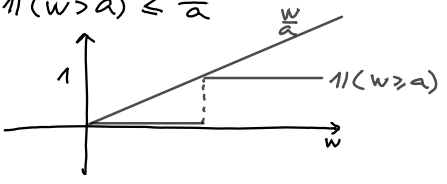

zed ■

Trditev 2.18

Ko je $p>0$ (za nek poljuben p) in so $W_1, W_2, \ldots$ take spremenljivke, da je $\lim_{n\to\infty} E(W_n^p) = 0$, gre tudi

$$W_n \xrightarrow[n\to\infty]{d/\mathbb{P}} 0$$

Dokaz:

$$\mathbb{P}(W_n \geq r) = \mathbb{P}(W_n^p \geq r^p) \leq \frac{E(W_n^p)}{r^p} \xrightarrow[n\to\infty]{} 0$$

zed ■

(Neki z razdaljo do 0)

Trditev 2.19 (šibki zakon velikih števil)

Če so $X_1, X_2, \dots$ neodvisne in enako porazdeljene realne slučajne spr. z $E(X_1^2) < \infty$ in $E(X_1) = \mu_1$, potem gre $\frac{X_1 + \dots + X_n}{n} \xrightarrow[n\to\infty]{d/\mathbb{P}} \mu_1$

Dokaz:

Ekvivalentno je dokazati da gre $\frac{X_1 + \dots X_n}{n} - \mu_1 \xrightarrow[n\to\infty]{\mathbb{P}} 0$

$$E\left(\left(\frac{X_1 + \dots + X_n}{n}\right) - \mu_1)^2\right) = var\left(\frac{X_1 + \dots + X_n}{n}\right) = \frac{1}{n^2} n \sigma_1^2 = \frac{\sigma_1^2}{n} \xrightarrow[n\to\infty]{} 0$$

zamaknjeno za pričakovano vrednost, zato vemo

$E(\dots) = 0$ (ker $E(X_1) = \mu_1$)

rezultat sledi iz trditve 2.18 qed ■

Opazka 2.20

(1) predpostavka, da je $E(X_1^2) < \infty$ je premočna. dovolj je, da je $E(|X_1|) < \infty$

(2) Tudi ob slednji predpostavki velja celo, da je

$$\mathbb{P}\left(\lim_{n\to\infty} \frac{X_1 + \dots + X_n}{n} = \mu_1\right) = \mathbb{P}\left(\left\{w ; \lim_{n\to\infty} \frac{X_1(w) + \dots + X_n(w)}{n} = \mu_1\right\}\right) = 1$$

Dokaz opuščamo

Trditev 2.21

Naj bodo $X_1, \dots X_n, X$ slučajne spremenljivke z vrednostmi v metr. prostoru (M, d), ter naj gre $X_n \xrightarrow[n\to\infty]{d} X$. Če je (M', d) še en metrični prostor in $g: M \longrightarrow M'$ zvezna, gre tudi

$$g(X_n) \xrightarrow[n\to\infty]{d} g(X)$$

Dokaz:

Če je $M' \longrightarrow \mathbb{R}$ zvezna in omejena, velja tudi za $h \circ g$

$$\begin{tikzcd} M \arrow[r, "g"] \arrow[dr, "h\circ g"'] & M' \arrow[d, "h"] \\ & \mathbb{R} \end{tikzcd}$$

$$\lim_{n\to\infty} E((h\circ g)(X)) = E((h\circ g)X)$$

$$\| \qquad\qquad \|$$

$$\lim_{n\to\infty} E(h(g(X))) \qquad E(h(g(X)))$$

$\blacksquare$ qed

Izrek 2.22

- Naj bo (M,d) metrični prostor.
- $\tilde{M} \subseteq M$ podprostor,
- $X_1, X_2, \ldots$ slč. spr. z vrednostmi v M
- $\tilde{X}$ slučajna spremenljivka z vrednostmi v $\tilde{M}$
- in naj gre $X_n \xrightarrow[n\to\infty]{d} \tilde{X}$
- Naj bo (M', d) še en metrični prostor
- $\tilde{g}: \tilde{M} \longrightarrow M'$ zvezna preslikava
- Naj bodo $Y_1, Y_2, \ldots$ take slč. sprem. z vrednostmi v M', da je $\lim_{n\to\infty} \mathbb{P}(X_n \in \tilde{M}, Y_n = \tilde{g}(X_n)) = 1$

Tedaj gre $Y_n \xrightarrow[n\to\infty]{d} \tilde{g}(\tilde{X})$

Dokaz: opustimo

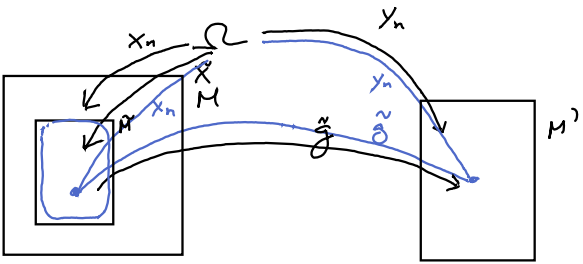

$\{X_n \in \tilde{M}, Y_n = \tilde{g} X_n\}$

Modre puščice komutirajo

Če gre $X_n \xrightarrow[n\to\infty]{d} X$ in $Y_n \xrightarrow[n\to\infty]{d} Y$,
ali lahko rečemo, da gre $(X_n, Y_n) \xrightarrow[n\to\infty]{d} (X, Y)$?

V splošnem ne.

Recimo, da gre $X_n \xrightarrow[n\to\infty]{d} X$ $Y_n \xrightarrow[n\to\infty]{d} Y$ in $(X_n, Y_n) \xrightarrow[n\to\infty]{d} (X, Y)$. Brž ko obstaja tak slučajni vektor (X', Y'), da je $X' \overset{d}{=} X$ in $Y = Y'$, toda $(X, Y) \overset{d}{\neq} (X', Y')$, gre tudi $X_n \xrightarrow[n\to\infty]{d} X'$ in $Y_n \xrightarrow[n\to\infty]{d} Y'$, ne more pa iti $(X_n, Y_n) \longrightarrow (X', Y')$
(po posledici 2.6)

	$Y=0$	$Y=1$	
$X=0$	$\frac{1}{6}$	$\frac{1}{3}$	$\frac{1}{2}$
$X=1$	$\frac{1}{6}$	$\frac{1}{3}$	$\frac{1}{2}$
	$\frac{1}{3}$	$\frac{2}{3}$	

	$Y=0$	$Y=1$	
$X=0$	$\frac{1}{3}$	$\frac{1}{6}$	$\frac{1}{2}$
$X=1$	0	$\frac{1}{2}$	$\frac{1}{2}$
	$\frac{1}{3}$	$\frac{2}{3}$	

Izrek 2.23

Naj bodo:

- $X_1, X_2, \dots$ in X slučajne spremenljivke z vrednostmi v (M, d_M)
- $Y_1, Y_2, \dots$ sluč. spr. z vrednostmi v (N, d_N)
- Naj bo $c \in N$ konstanta
- Za poseben $n \in \{1, 2, \dots\}$, naj bosta X_n in Y_n definirani na istem verjetnostnem prostoru.
- Opremimo produkt $M \times N$ z metriko $d_{M\times N}$, ki izpolnjuje naslednje:
  1) za $\forall x_1, x_2 \in M.\ d_{M\times N}((x_1, c), (x_2, c)) \leq d_M(x_1, x_2)$
  2) $\forall x \in M. \forall y \in N.\ d_{M\times N}((x, y), (x, c)) \leq d_N(y, c)$

Tedaj, če gre $X_n \xrightarrow[n\to\infty]{d} X$ in $Y_n \xrightarrow[n\to\infty]{d} c$, gre tudi $(X_n, Y_n) \xrightarrow[n\to\infty]{d} (X, c)$

Dokaz:

Ker je vložitev $\iota: M \to M\times N,\ x \mapsto (x, c)$ zvezna, gre po trditvi 2.21 $(X_n, c) \to (X, c)$.

Ker gre $Y_n \xrightarrow[n\to\infty]{d} c$ gre po trditvi 2.15 tudi $Y_n \xrightarrow[n\to\infty]{P} c$, ker pomeni:

$$\forall r > 0.\ \lim P(d_n(Y_n, c) \geq r) = 0$$

Po predpostavkah je tedaj tudi

$$\lim_{n\to\infty} P(d_{M\times N}((X_n, Y_n), (X_n, c)) \geq r) = 0, \quad (\text{po } 2))$$

ali ekvivalentno $d_{M\times N}((X_n, Y_n), (X_n, c)) \xrightarrow[n\to\infty]{P/d} 0$.

Rezultat sledi iz trditve 2.13 (2)

$\blacksquare$

ged

Posledica 2.24 (šibki zakon velikih števil za slučajne vektorje)

če so

$$X_1 = \begin{bmatrix} X_1^{(1)} \\ \vdots \\ X_1^{(m)} \end{bmatrix}, \quad X_2 = \begin{bmatrix} X_2^{(1)} \\ \vdots \\ X_2^{(m)} \end{bmatrix}, \ldots$$

neodvisni in enako porazdeljeni slučajni vektorji z $E(\|X_1\|^2) < \infty$ in

$$\underline{\mu} = \begin{bmatrix} E(X_1^{(1)}) \\ \vdots \\ E(X_1^{(m)}) \end{bmatrix}, \text{ gre } \quad \frac{\underline{X_1} + \underline{X_2} + \ldots + \underline{X_n}}{n} \xrightarrow[n\to\infty]{d} \underline{\mu}$$

Dokaz: $\square$

Izreki Slutskega (2.25, 2.26, 2.27, 2.28)

Posledica 2.25

Naj bodo $X_1, X_2, \ldots$ in $Y_1, Y_2, \ldots$ sluč. vek. z vred. v $\mathbb{R}$

Če gre $X_n \xrightarrow[n\to\infty]{d} X$ in $Y_n \xrightarrow[n\to\infty]{d} c$, kjer je c konstanta, gre tudi $X_n + Y_n \xrightarrow{d} X + c$

in $X_n - Y_n \xrightarrow{d} X - c$

Dokaz: $\square$

Posledica 2.26

- Naj bodo $X_1, X_2, \ldots$ sluč. vek. z vrednostmi v $\mathbb{R}^n$
- in $U_1, U_2, \ldots$ realne sluč. spr.
- Naj gre $X_n \xrightarrow{d} X$ in $U_n \xrightarrow{d} U$

Če je X ali U konstanta, gre tudi

$U_n \underline{X_n} \xrightarrow{d} U \underline{X}$

Dokaz: $\square$

Trditev: 2.27

- Naj bodo $X_1, X_2, \dots$ in $Y_1, Y_2, \dots$ slučj. vekt. z vrd. v $\mathbb{R}^m$
- $U_1, U_2, \dots$ realne slučj. spr.
- Za posamezen n naj bodo X_n, Y_n, U_n definirani na istem verjetnostnem prostoru.
- Naj gre $X_n \xrightarrow{d} X$ in $U_n \xrightarrow{d} c$ $c \in \mathbb{R} - \{0\}$ konst.
- Naj bo $\lim_{n\to\infty} P(X_n = U_n Y_n) = 1$

Tedaj gre $Y_n \xrightarrow{d} \frac{1}{c} \cdot X$

Dokaz: Uporabimo 2.22

$M := \mathbb{R}^m \times \mathbb{R}$ $\quad M' := \mathbb{R}^m$ $\quad \tilde{M} := \mathbb{R}^m \times (\mathbb{R} - \{0\})$

Po izreku 2.23 gre $(X_n, U_n) \longrightarrow (X, c)$

$\tilde{g} : \tilde{M} \to \mathbb{R}^m$ $\quad (x, u) \mapsto \frac{1}{u} x$

$\{(X_n, U_n) \in \tilde{M}\ Y_n = g(X_n, U_n)\} = \{U_n \neq 0, X_n = U_n Y_n$

Ker je $\tilde{M}$ odprta in (X, c) zavzame vrednosti v $\tilde{M}$ je po opazki 2.10 je

$$\lim_{n\to\infty} P((X_n, U_n) \in \tilde{M}) = \lim_{n\to\infty} P(U_n \neq 0) = 1$$

Sledi $P((X_n, U_n) \in \tilde{M}, Y_n = g(X_n, U_n)) \longrightarrow 1$

in pogoji izreka 2.23 so izpolnjeni.

$\blacksquare$ qed

Trditev 2.28

- Naj bodo $X_1, X_2 \dots$ in $U_1, U_2 \dots$ real. slučj. spr.
- Naj gre $X_n \xrightarrow{d} X$, $U_n \xrightarrow{d} c$, kjer je $c \in \mathbb{R} - \{0\}$

Tedaj za

$\forall a \in \mathbb{R}$. $P(\frac{X}{c} = a) = 0 \Rightarrow$

$$\lim_{n\to\infty} P(U_n \neq 0, \frac{X_n}{U_n} < a) = \lim_{n\to\infty} P(U_n \neq 0, \frac{X_n}{U_n} \leq a) = P(\frac{X}{c} \leq a)$$

in

$$\lim_{n\to\infty} P(U_n \neq 0, \frac{X_n}{U_n} > a) = \lim_{n\to\infty} P(U_n \neq 0, \frac{X_n}{U_n} \geq a) = P(\frac{X}{c} \geq a)$$

Dokaz:

Uporabimo trditev 2.27 tako, da najprej postavimo $Y_n := \begin{cases} \frac{X_n}{U_n} & ; U_n \neq 0 \\ a+1 & ; U_n = 0 \end{cases}$

neko število, ki je večje od a

Tako je $\{U_n \neq 0, \frac{X_n}{U_n} < a\} = \{Y_n < a\}$

Po opazki 2.10 velja

$$\lim P(U_n \neq 0) = \lim (U_n \neq 0, Y_n = \frac{X_n}{U_n}) = 1$$

Po trditvi 2.27 gre potem $Y_n \xrightarrow{d} \frac{X}{c}$ po definiciji II. Po Haley-Brayevem izreku pa gre $Y_n \xrightarrow{d} \frac{X}{c}$ tudi po definiciji I, torej velja

$$\lim_{n\to\infty} P(Y_n < a) = \lim_{n\to\infty} P(Y_n \leq a) = P(\frac{X}{c} \leq a)$$

Uporabimo

Drugo konvergenco dobimo, da X_n, X zamenjamo z $-X_n, -X$

■ qed

Mehak uvod v sklepno statistiko

verjetnostno vprašanje : $P(A)$

Vprašanje sklepne statistike:

Opazimo da se je zgodil dogodek A.

$\mathbb{P}_\vartheta$; $\vartheta \in \Theta$

kaj lahko vsaj približno povemo o ϑ

Thomas Bayes (ok 1701-1761)

ϑ naj bo slučajna spremenljivka z neko apriorno porazdelitev

$$\mathbb{P}_t(A) = \mathbb{P}(A \mid \vartheta = t)$$

Sir Ronald Aymler Fisher (1890-1962)

sprejmemo šibkejše rezultate, ki so porazdelitve nečesa v zvezi z A in ϑ

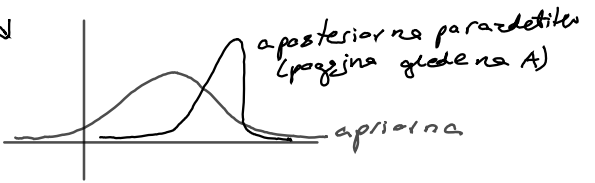

Torej porazdelitev bolje poznamo, ko vemo A

Zgled:

$\mathbb{P} = \mathbb{P}_\mu \qquad \mu \in \mathbb{R}$

Recimo da pri $\mathbb{P}_\mu$ velja $X \sim N(\mu, 1)$

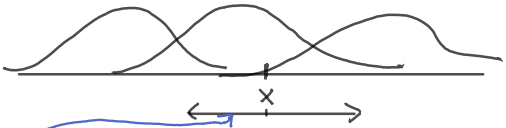

cenilka / ocena za μ po metodi največjega verjetja: $\hat{\mu} = x$:

pri danem x je gostota največja za $\mu = x$

Sklepamo da je μ najbrž nekje na intervalu zaupanja

Stopnja tveganja α: maksimalna dopustna verjetnost zmote, tipično 5%

Naj bodo $X_1, X_2, \ldots$ neodvisne in enako porazdeljene z $E(X_1) = \mu$ in $var(X_1) = \sigma^2$ $\sigma > 0$

Zanima nas μ, ki ni znan, znani pa so $x_1, x_2, \ldots x_n$ - opažene vrednosti

Ena možnost je, da je znan tudi σ

$$\hat{\mu} = \bar{X} = \frac{X_1 + \ldots + X_n}{n}$$

(izhaja iz zakona velikih števil $\bar{X} \xrightarrow[n \to \infty]{d} \mu$)

$\bar{X}$ je dosledna cenilka za μ (dobivamo vedno več informacij za μ (šibka doslednost)

Za koliko si upamo reči, da $\bar{X}$ odstopa od μ

želimo sklepati, da je $\bar{X} - \delta < \mu < \bar{X} + \delta$

Cilj: najti čim manjši δ za katerega bo $\underbrace{\mathbb{P}(|\bar{X} - \mu| \geq \delta)}_{\text{zmota}} < \alpha$

1

Če vemo, da je $X_1 \sim N(\mu, \sigma^2)$ in poznamo σ, vemo:

$$\bar{X} - \mu \sim N\left(0, \frac{\sigma^2}{\sqrt{n}}\right)$$

$$\parallel$$

$$\frac{n\sigma^2}{n^2} \qquad Z := \frac{\bar{X}-\mu}{\sigma}\sqrt{n} \sim N(0,1)$$

$$P(|\bar{X}-\mu| > \delta) = P\left(|Z| \geq \frac{\delta}{\sigma}\sqrt{n}\right) = 2P\left(Z > \frac{\delta}{\sigma}\sqrt{n}\right) =$$

$$2\left(1 - \Phi\left(\frac{\delta}{\sigma}\sqrt{n}\right)\right) \leq \alpha$$

$$\Rightarrow \Phi\left(\frac{\delta}{\sigma}\sqrt{n}\right) \geq 1 - \frac{\alpha}{2}$$

$$\delta \geq \frac{\sigma}{\sqrt{n}}\Phi^{-1}\left(1-\frac{\alpha}{2}\right)$$

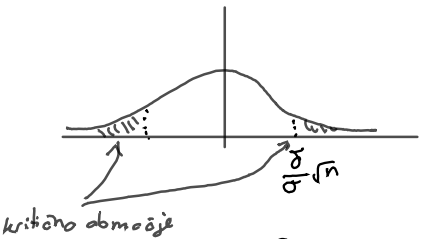

$$\Rightarrow \delta = \frac{\sigma}{\sqrt{n}}\Phi^{-1}\left(1-\frac{\alpha}{2}\right)$$

$$\alpha = 0{,}05: \quad \Phi^{-1}\left(1-\frac{\alpha}{2}\right) = 1{,}96$$

Interval zaupanja za μ je $\bar{X} - \frac{\sigma}{\mu}\Phi^{-1}\left(1-\frac{\alpha}{2}\right)$, $\bar{X} + \frac{\sigma}{\sqrt{n}}\Phi^{-1}\left(1-\frac{\alpha}{2}\right)$

Ta interval zaupanja je eksakten

② Če nismo prepričani, da so $X_1, \dots X_n$ porazdeljene normalno, nam na pomoč priskoči centralni limitni izrek. Pri velikih n bo

$$\mathbb{P}\left(|\bar{X} - \mu| \geq \frac{\sigma}{\sqrt{n}} \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)\right) \approx \alpha$$

α je zdaj le še nominalna stopnja tveganja, konstruirani interval zaupanja pa je asimptotično eksakten

③ Kaj pa, če σ ne poznamo?
Ideja: Nadomestimo ga s pristoliškom

Ideja za oceno σ izhaja iz empirične porazdelitve

$$Emp(x_1, x_2 \dots, x_n) := \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ \frac{1}{n} & \frac{1}{n} & \dots & \frac{1}{n} \end{pmatrix},$$

če so si $x_1 \dots x_n$ različni, čepa nise, pa ustrezne vrjetnosti seštejemo

Npr: $Emp(2, 1, 2, 3, 7) = \begin{pmatrix} 1 & 2 & 3 & 7 \\ \frac{1}{5} & \frac{2}{5} & \frac{1}{5} & \frac{1}{5} \end{pmatrix}$

$\bar{x} = \frac{x_1 + \dots + x_n}{n} = \mathbb{E}(W)$, kjer je $W \sim Emp(x_1 \dots x_n)$

Povprečje je empirična pričakovana vrednost
empirični standardni odklon pa je

$$\sigma_{emp} = \sqrt{var(W)} = \sqrt{\frac{(x_1 - \bar{x})^2 + \dots (x_n - \bar{x})^2}{n}}$$

Cenilka za σ:

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2}$$

Ali je cenilka na mestu?

Ali gre $\hat{\sigma} \xrightarrow[n\to\infty]{d} \sigma$

Iz zakona velikih števil sledi

$$\frac{(X_1-\mu)^2+(X_2-\mu)^2+\dots+(X_n-\mu)^2}{n} \xrightarrow[n\to\infty]{d} \sigma^2$$

$var(W) = var(W-\mu)$

$$\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2 - \underbrace{(\bar{X}-\mu)^2}_{\substack{\downarrow \\ 0}}$$

1. zakon velikih števil

2. trditev 2.21

Po izreku slutskega gre tudi:

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^2 \xrightarrow[n\to\infty]{d} \sigma^2$$

v okviru $\mathbb{R}$,

po opazki 2.9 pa tudi v okviru $[0,\infty)$

Spet po trditvi 2.21 gre tudi $\hat{\sigma} \xrightarrow{d} \sigma$

$\frac{\hat{\sigma}}{\sigma} \longrightarrow 1$

Zdi se:

$$\frac{\bar{X}-\mu}{\hat{\sigma}} = \frac{\frac{\bar{X}-\mu}{\sigma}}{\frac{\hat{\sigma}}{\sigma}} \xrightarrow[n\to\infty]{d} N(0,1)$$

slutski (2.27)

Torej je $\left(\bar{X}-\frac{\hat{\sigma}}{\sqrt{n}}\Phi^{-1}\left(1-\frac{\alpha}{2}\right), \bar{X}+\frac{\hat{\sigma}}{\sqrt{n}}\Phi^{-1}\left(1-\frac{\alpha}{2}\right)\right)$

asimptotično ekskluten interval zaupanja

konvergira proti α,

ko gre $n\to\infty$

Kaj če je $\hat{\sigma}=0$? (ko so vse opažene vrednosti enake) Interval zaupanja ima še vedno smisel, ampak konvergenca pa nima pomena

μ je izven konstruiranega IZ v naslednjih primerih:

* $\hat{\sigma}=0$
* $\hat{\sigma}\neq 0$ $\quad \frac{\bar{X}-\mu}{\hat{\sigma}}\sqrt{n} \leq -\Phi^{-1}\left(1-\frac{\alpha}{2}\right) = \Phi^{-1}\left(\frac{\alpha}{2}\right)$
* $\hat{\sigma}\neq 0$ $\quad \frac{\bar{X}-\mu}{\hat{\sigma}}\sqrt{n} \geq \Phi^{-1}\left(1-\frac{\alpha}{2}\right)$

Ker gre $\hat{\sigma} \xrightarrow[n\to\infty]{d} \sigma > 0$, je $\lim \mathbb{P}(\hat{\sigma}=0)=0$.

Po trditvi 2.28 pa je

$$\lim \mathbb{P}\left(\hat{\sigma}\neq 0, \frac{\bar{X}-\mu}{\hat{\sigma}}\sqrt{n} \leq \Phi^{-1}\left(\frac{\alpha}{2}\right)\right) = \mathbb{P}\left(Z \leq \Phi^{-1}\left(\frac{\alpha}{2}\right)\right)$$

Če to sklepanje uporabimo za $-X_1, -X_2, \dots$, pa dobimo še:

$$\lim \mathbb{P}\left(\hat{\sigma}\neq 0, \frac{\bar{X}-\mu}{\hat{\sigma}}\sqrt{n} \geq \Phi^{-1}\left(1-\frac{\alpha}{2}\right)\right) = \frac{\alpha}{2}$$

3. IZVLEČEK OPISNE STATISTIKE

statistika : $f(\overbrace{x_1, \dots, x_n}^{\text{opažene vrednosti}})$

n - število opažanj ali numerus

Primeri statistik:

1. aritmetična sredina ali povprečje

$$\bar{x} = \frac{x_1 + \dots + x_n}{n} = \mathbb{E}(Emp(x_1, \dots, x_n))$$

2. empirična varianca

$$\frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2 = var(Emp(x_1, \dots, x_n))$$

3. vrstilne statistike

$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ je ustrezna permutacija zaporedja opaženih vrednosti

$x_{(k)}$ je k-ta vrstilna statistika

$x_{(1)}$ = minimum , $x_{(n)}$ = maksimum

Definicija: Kvantil slučajne spremenljivke X oz njene porazdelitve za vrjetnost $\alpha \in (0,1)$ je poljubno število x_α, za katerega je

$$\mathbb{P}(X < x_\alpha) \leq \alpha \leq \mathbb{P}(X \leq x_\alpha)$$

Če je X porazdeljena zvezno je $P(X \leq x_\alpha) = \alpha$

Opazka 3.1.

Če je gostota na nekem odprtem intervalu $I \subseteq \mathbb{R}$ strogo pozitivna, drugje pa je enaka 0, je $F_X : I \to (0,1)$ bijektivna in velja

$$x_\alpha = F_X^{-1}(\alpha)$$

$\Phi^{-1}(0{,}975) \doteq 1{,}96$ je kvantil standardne porazdelitve za vrjetnost $0{,}975$

Definicija: Kvantil za delež α, ki pripada danim podatkom, je kvantil njihove empirične porazdelitve za vrjetnost α

Primer:

$$Emp(1,1,2,3,5) = \begin{pmatrix} 1 & 2 & 3 & 4 & 5 \\ \frac{2}{5} & \frac{1}{5} & \frac{1}{5} & \frac{0}{5} & \frac{1}{5} \end{pmatrix}$$

Kvantil za delež $\frac{1}{2}$ je 2)

$$P(X<2) \leq \frac{1}{2} \leq P(X \leq 2)$$

Recimo da $x<2 \Rightarrow P(X \leq x) \leq P(X<2) = \frac{2}{5} < \frac{1}{2}$

Recimo da $x>2 \Rightarrow P(X<x) \geq P(X \leq 2) = \frac{3}{5} > \frac{1}{2}$

zato je $x=2$ edini možni kvantil za $\frac{1}{2}$

Kvantil za delež $\frac{3}{5}$ so $x \in [2,3]$

$$\frac{2}{5} = P(X<2) \leq P(X<x) \leq P(X<3) = \frac{3}{5}$$

$$\frac{3}{5} = P(X \leq 2) \leq P(X<x) \leq P(X \leq 3) = \frac{4}{5}$$

Trditev 3.2: Vsi možni kvantili dane verjetnostne porazdelitve za dano verjetnost $\alpha \in (0,1)$ (in z njimi vsi možni kvantili danih podatkov za delež za α) tvorijo zaprt interval $[x_\alpha^-, x_\alpha^+]$, kjer je x_α^- spodnji kvantil x_α^+, ki je lahko izrajen ($\{x_\alpha\}$), ne more pa biti prazen.

Dokaz: DN

$X_{\frac{1}{2}} = m$ imenujemo mediana

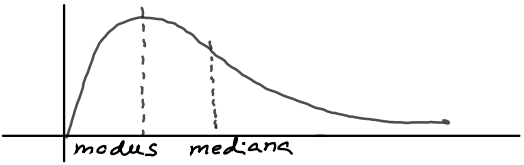

$X_{\frac{1}{3}}$ in $X_{\frac{2}{3}}$ sta prvi in drugi tercil

$X_{\frac{1}{4}}, X_{\frac{2}{4}} = m, X_{\frac{3}{4}}$ so kvartili

$X_{0,1}, X_{0,2}, \dots X_{0,9}$ so decili

$X_{0,01}, \dots X_{0,09}$ so centili ali percentili

Kvantilom radi pripisujemo arbitrarne vrednosti.
Za mediano je to $\frac{X_{\frac{1}{2}}^- + X_{\frac{1}{2}}^+}{2}$.

Definicija: Interaktivni razmik (interquartal range ali mid fifty) je razlika med 1. in 3. kvartilo

$IQR := X_{\frac{3}{4}}^+ - X_{\frac{1}{4}}^-$

Aritmetična sredina in mediana sta mei centralne tendence.

IQR in standardni odklon sta mei razpršenosti

Frekvence

Frekvenca je število enot z določeno lastnostjo, ki je navadno vezana na določeno statistično spremenljivko.

Relativna frekvenca ali delež je frekvenca, deljena s številom podatkov

Podatke razvrstimo v razrede. Tako dobimo histogram

Kako široki naj bodo razredi?
Ideja: Če podatki izhajajo iz neke zvezne porazdelitve, naj bo histogram čim bližje gostoti te porazdelitve.

Širina $\approx \sigma \sqrt[3]{\frac{24\sqrt{\pi}}{n}} \approx \frac{3{,}5\sigma}{\sqrt[3]{n}}$

$$\text{širina} \approx \sigma \sqrt[3]{\frac{24\sqrt{\pi}}{n}} \doteq \frac{3{,}5\sigma}{\sqrt[3]{n}}$$

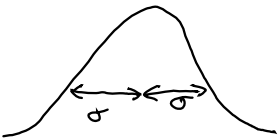

$h :=$ ~ širina stolpca
ista velikostni red

glavnina porazdelitve:

širina ~ σ

št. razredov ~ $\frac{\sigma}{h}$

enot ~ n

maksimalna pričakovana frekvenca ~ $n : \frac{\sigma}{h} = \frac{nh}{\sigma}$

Tudi pričakovana frekvenca za razred iz glavnine

Posamezen podatek pade v razred iz glavnine z verjetnostjo $\sim Bin(n, \sim\frac{h}{\sigma}) \approx Pois\left(\frac{nh}{\sigma}\right)$

Standardni odklon take frekven je $\sim \sqrt{\frac{nh}{\sigma}}$

= velikostni red šuma

Pričakovana razlika med tipičnima sosednjima razredoma ~ $\frac{nh}{\sigma} : \frac{\sigma}{h} = \frac{nh^2}{\sigma^2}$

$$\sqrt{\frac{nh}{\sigma}} \sim \frac{nh^2}{\sigma^2} \rightsquigarrow \frac{nh}{\sigma} \sim \frac{h^2 h^4}{\sigma^4} \rightsquigarrow h \sim \frac{\sigma}{\sqrt[3]{n}}$$

če izenačimo trend in šum do konstante

Pr: gaussovi porazdelitvi je

$$IQR = \sigma\left(\Phi^{-1}\left(\tfrac{3}{4}\right) - \Phi^{-1}\left(\tfrac{1}{4}\right)\right)$$

Če v Scottovem pravilu σ nadomestimo z $\dfrac{IQR}{\Phi^{-1}\left(\frac{3}{4}\right) - \Phi^{-1}\left(\frac{1}{4}\right)}$, dobimo modificirano Freedman-Diaconisovo porazdelitev

Vprašanje

Kaj naredi na naš vtis kolišine na histogramu? Plošče

gostota frekvence $:= \dfrac{\text{frekvenca}}{\text{širina razreda}}$

relativna gostota frekvence $:= \dfrac{\text{frekvenca}}{\text{numerus} \cdot \text{širina razreda}}$

Splača se izločiti osamelce tj. vrednosti vrednosti izven intervala $\left[x_{\frac{1}{4}} - \frac{3}{2} IQR,\ x_{\frac{3}{4}} + \frac{3}{2} IQR\right]$

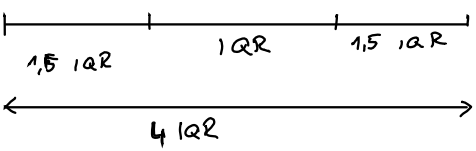

$\mathbb{P}$(pri normalni porazdelitvi dobimo osamelca)

$$= 2 \cdot \left(1 - \Phi\left(4\Phi^{-1}\left(\tfrac{3}{4}\right)\right)\right) \doteq 0{,}006977$$

Primerjalni kvantilni (Q-Q) grafikon

Služi primerjavi dveh verjetnostnih porazdelitev. V najbolj „teoretični" različici ga sestavljajo vse možne točke (x,y), kjer je x kvantil prve porazdelitve, y pa druge za $\alpha \in (0,1)$

Primer

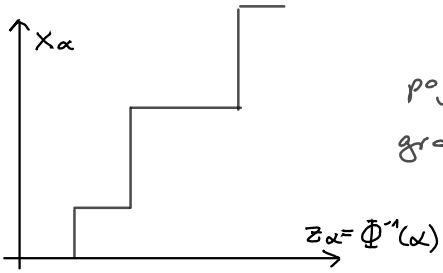

jš nimam pojma kaj ta graf hoče povedat

Dve zvezni porazdelitvi se ujemata $\Leftrightarrow$ njun primerjalni kvantilni grafikon je simetrala lihih kvadrantov

Kadar pa empirično porazdelitev primerjamo z določeno teoretično porazdelitvijo navadno narišemo le kvantile za verjetnosti $\frac{1}{n+1}, \frac{2}{n+1}, \dots \frac{n}{n+1}$. Kvantili za te verjetnosti so vedno natančno določeni, enaki pa so kar $X_{(1)}, \dots, X_{(n)}$

Q-Q grafikon med dvema neizrojenima Gaussovima porazdelitvama je vedno premica. Poznamo Shapiro-Wilkov preizkus normalnosti

Škatla z brki

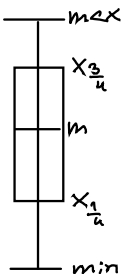

4. Ocenjevanje in napovedovanje

Opis problema:

Dobimo določene podatke za X, zanima nas y

Primer: Problem trgovskega potnika

X = graf z uteženimi povezavami

y = optimalni obhod

Matematični model $\rightarrow$ verjetnostni/stohastični model

$\downarrow$

statistični model

Stohastični model vsebuje slučaj: Vsaj ena od količin X in y modeliramo kot slučajno. Tako y tipično ni natančno določen z X.

Statistični model običajno upošteva še ponavljanje

Ena izmed glavnih nalog sklepne statistike je najti opazljivo količino $\hat{Y}$, $\hat{Y} = h(X)$, kjer je h merljiva, izračunljiva funkcija, da bo $\hat{Y}$ čim bližje Y.

V Bayesovem modelu sta X in Y slučajni spremenljivki na $(\Omega, \mathcal{F}, P)$

Če poznamo X in če Y živi v $\mathbb{R}$, je smiselna napoved/predikator za Y slučajna spremenljivka $E(Y|X) = h(X)$

Diskreten primer: $\hat{Y} = h(X)$ $h(x) = E(Y|X=x)$
Poznamo $P(X=x|Y=y)$. Privzamemo apriorno porazdelitev napovedovalca/predikata Y. Po Bayesovi formuli izračunamo $P(Y=y|X=x)$. Iz slednjih dobimo napoved $E(Y|X=x)$

Fisherjeva statistika na $(\Omega, \mathcal{F})$ pa gleda celo družino verjetnostnih mer P_ϑ, $\vartheta \in \Theta$

Splošno: $X = F(\omega, \vartheta)$, $Y = G(\omega, \vartheta)$

Dostikrat je Y karakteristika modula, torej $Y = y = g(\vartheta)$. Tipično je $X = X(\omega)$

Primer:

Opazimo $X_1, \dots, X_n$, neodvisne, porazdeljene kot $N(\mu, \sigma^2)$

$\Theta = \mathbb{R} \times (0, \infty)$ $\quad \vartheta = (\mu, \sigma)$

Ocenjujemo naprimer:

- $g(\mu, \sigma) = \mu$
- $g(\mu, \sigma) = \sigma^2$
- $g(\mu, \sigma) = \mu^2$
- $g(\mu, \sigma) = \mu + 2\sigma$ (VaR)

Terminološko pojasnilo:

	deterministična	slučajna
poznamo	konstanta	opažanje
nepoznamo	karakteristika	predikat ali šum

Če je predmet našega zanimanja karakteristika, potem namesto o predikatorju govorimo o cenilki: preden opazimo podatke, in o ceni potem ko jih opazimo.

Primer: Vrnimo se k prejšnjemu primeru

$$X_k = \mu + \varepsilon_k \quad k \in \{1, \dots n\}$$

$\varepsilon_k \sim N(0, \sigma_k^2)$ so šumi

smiselna cenilka za μ je

$$\hat{\mu} = \frac{X_1 + \dots + X_n}{n} = \overline{X}$$

Vrednote cenilk in predikatorjev

Naj bo $\hat{y} = h(X)$ cenilka za y

slučajna spremenljivka

Definicija: Pričakovana ali srednja kvadratična napaka cenilke $\hat{y}$ karakteristike y je

$$MSE_\vartheta(\hat{y}|y) := E_\vartheta((\hat{y}-y)^2)$$

mean squared error

ne označuje pogojevanja

pričakovana vrednost pri verjetnostni meri P_ϑ

Definicija: Korenjena pričakovana kvadratična napaka cenilke $\hat{y}$ karakteristike y je:

$$RMSE_\vartheta(\hat{y}|y) := \sqrt{MSE_\vartheta(\hat{y}|y)}$$

Definicija: Pristranskost cenilke $\hat{y}$ za y je

$$Bias_\vartheta(\hat{y}|y) := E_\vartheta(\hat{y}) - y = E_\vartheta(\hat{y} - y)$$

Definicija: Cenilka je nepristranska, če za $\forall \vartheta \in \Theta$. $Bias(\hat{y}|y) = 0$

Opazka 4.1:

Če je cenilka nepristranska, je

$$MSE_\vartheta(\hat{y}|y) = var_\vartheta(\hat{y}) = var_\vartheta(\hat{y}-y).$$

V tem primeru označimo standardno napako

$$SE := \sqrt{var_\vartheta(\hat{y})}$$

V splošnem pa velja:

$$var_\vartheta(\hat{y}) = Var_\vartheta(\hat{y}-y) = E_\vartheta((\hat{y}-y)^2) - E(\hat{y}-y)^2 =$$

$$= MSE_\vartheta(\hat{y}|y) - (Bias_\vartheta(\hat{y}|y))^2$$

$$\Longrightarrow MSE_\vartheta(\hat{y}|y) = var_\vartheta(\hat{y}) + (Bias(\hat{y}|y))^2$$

Definicija:

Zaporedje cenilk $\hat{y}_1, \dots$ je šibko dosledno za y, če v porazdelitvi konvergira proti y:

$$\forall \vartheta \in \Theta.\ \hat{y}_n \xrightarrow[n\to\infty]{d|\vartheta} y = y(\vartheta)$$

Trditev 4.2.

Brž ko je $\forall \vartheta \in \Theta.\ \lim_{n\to\infty} MSE_\vartheta(\hat{y}_n | y) = 0$, je zaporedje cenilk $\hat{y}_1, \hat{y}_2, \dots$ šibko dosledno za y

Dokaz: Sledi iz trditve 2.18:

$$W_n \geq 0 \quad p > 0 \quad \lim E(W_n^p) = 0 \Rightarrow W_n \xrightarrow[n\to\infty]{d} 0$$

Po posledici 2.16 velja:

$$X_n \xrightarrow[n\to\infty]{d} c \iff d(X_n, c) \xrightarrow[n\to\infty]{d} 0$$

Vstavimo:

$$X_n = \hat{y}_n,\ c = y,\ p = 2,\ W_n = |\hat{y}_n - y|,\ d(a,b) = |b-a|$$

$\blacksquare$

Posledica: Če je zaporedje cenilk $\hat{y}_n$ za y asimptotično nepristransko ($\forall \vartheta \in \Theta.\ \lim_{n\to\infty} E_\vartheta(\hat{y}) = y$) in če tudi $\forall \vartheta \in \Theta.\ \lim_{n\to\infty} var_\vartheta(\hat{y}_n) = 0$, je to zaporedje šibko dosledno za y.

Primer:

Naj bodo $X_1, X_2, \dots$ enako porazdeljene s pričakovano vrednostjo μ in varianco σ^2.

$$\mu = E_\vartheta(X_1) = g(\vartheta)$$

Tedaj je $\hat{\mu} = \bar{X}$ nepristranska cenilka za μ.

Ni pa nujno šibko dosledna. Lahko je denimo $X_1 = X_2 = \dots$ in $\sigma > 0$

Če pa prevzememo, da so $X_1, \dots$ nekorelirane pa je $\hat{\mu}$ tudi šibko dosledna.

$$MSE(\bar{X} \mid \mu) = var(\bar{X}) = \frac{\sigma^2}{n}$$

$$RMS(\bar{X} \mid \mu) = SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

Ko gre $n \to \infty$ gre $MSE \to 0$, torej je $\hat{\mu}$ šibko dosledna za μ

Če so $X_1, X_2, \dots$ neodvisne pa je po zakonu velikih števil (opazka 2.20 (1)) to velja tudi brez predpostavke o končnem drugem momentu.

Zaporedje cenilk $X_1, X_2 \dots$ pa ni šibko dosledno za μ

V resnici je $\bar{X}$ najboljša nepristranska linearna cenilka (NNLC, best linear unbiased estimator, BLUE) za μ.

Če je μ fiksen in so $c_1, \dots c_n$ take konstante, da je $\hat{\mu} = c_1 X_1 + \dots + c_n X_n$ nepristranska cenilka za μ, velja:

$$\underset{\substack{\parallel \\ Var(c_\mu)}}{MSE(\hat{\mu} | \mu)} \geq MSE(\bar{X} | \mu)$$

Za sledje je dovolj privzeti nekoreliranost

Če pa je model Gaussov ($X_1, X_2, \dots$ neodvisne in porazdeljene kot $N(\mu, \sigma^2)$), ter velja še eden izmed naslednjih pogojev:

1) σ je konstanten, torej znan
2) μ in σ se spreminjata neodvisno drug od drugega

Potem je $\bar{X}$ tudi najboljša nepristranska cenilka za μ nasploh. (za tem stoji Rao-Cramerjeva ocena)

Če dopustimo kar vse cenilke, pa tipično nobena ni enakomerno najboljša

Če ocenjujemo μ^2 je tipično $\bar{X}^2$ pristranska, saj

$$\mathbb{E}(\bar{X}^2) = \mathrm{var}(\bar{X}) + \mathbb{E}(\bar{X})^2 = \frac{\sigma^2}{n} + \mu^2$$

je pa asimptotično nepristranska:

$$\mathrm{Bias}(\bar{X}^2 | \mu^2) = \frac{\sigma^2}{n} \xrightarrow[n\to\infty]{} 0 \text{ za } \forall \vartheta \in \Theta$$

je tudi šibko nedosledna (po trditvi 2.21:

če gre $X_n \xrightarrow{d} X$ in g zvezna gre $g(X_n) \xrightarrow[n\to\infty]{} g(X)$

Splošni primer, ko je $\hat{y} = h(X)$ prediktor za $y = G(\omega, \vartheta)$:

ostane $MSE_\vartheta(\hat{y}|y) = E_\vartheta((\hat{y} - y)^2)$.

Če za $\forall \vartheta \in \Theta$. $E_\vartheta(\hat{y}) = E_\vartheta(y)$, je nujno $MSE_\vartheta(\hat{y}|y) = \mathrm{var}_\vartheta(\hat{y} - y)$, tipično pa to ni več enako $\mathrm{var}_\vartheta(\hat{y})$

Primer:

Naj bodo $X_1, X_2 \dots$ nekorelirane in enako porazdeljene s pričakovano vrednostjo μ in varianco σ^2.

$$X_i = \mu + \varepsilon_i$$

$\varepsilon_1, \varepsilon_2 \dots$ tvorijo bel šum, ker pomeni, da so nekorelirane s pričakovano vrednostjo 0 in enakimi variancami

Opazimo: $X = (X_1 \dots X_n)$, zanima nas $Y = X_{n+1}$

$$Y = \mu + \varepsilon_{n+1}$$

Predikator za Y: $\hat{X}_{n+1} = \hat{Y} = \frac{X_1 + \dots + X_n}{n} = \bar{X}$

Ta predikator je nepristranski v smislu

$$E(\hat{X}_{n+1}) = E(X_{n+1})$$

$$MSE = var(\bar{X} - X_{n+1}) = var(\bar{X}) + var(X_{n+1}) =$$

$$= \frac{\sigma^2}{n} + \sigma^2 = \sigma(1 + \frac{1}{n}$$

5. Pričakovana vrednost in varianca večrazsežnih slučajnih objektov

Definicija: Za slučajni vektor $X = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$ definiramo pričakovano vrednost

$$E(X) = \begin{bmatrix} E(x_1) \\ \vdots \\ E(x_n) \end{bmatrix}$$

Trditev 5.1

Za deterministično matriko A in slučajni vektor X kompatibilnih dimenzij velja $E(AX) = AE(X)$

Dokaz: DV

Posledica 5.2

Če je u determinističen, X pa slučajni vektor velja:

$$E(\langle X, u \rangle) = \langle E(X), u \rangle$$

$$\overset{\shortparallel}{E(u^T X)} = u^T \overset{\shortparallel}{E(X)}$$

Definicija: Za slučajno matriko $M = [M_{ij}]_{ij}$ definirajmo $\mathbb{E}(M) := [E(M_{ij})]_{ij}$

Trditev 5.3:

Naj bo M slučajna matrika.

1) Velja $E(M^T) = E(M)^T$

2) Za poljubni deterministični matriki A in B primernih velikosti, velja:

$$\mathbb{E}(AM) = A\mathbb{E}(M) \text{ in } \mathbb{E}(MB) = \mathbb{E}(M)B$$

Dokaz: DV

Trditev 5.4:

Za poljubna enako velika slučajna vektorja $\mathbb{E}(X+Y) = \mathbb{E}(X) + \mathbb{E}(Y)$, tej za poljubni enako veliki slučajni matriki velja

$$\mathbb{E}(M+N) = \mathbb{E}(M) + \mathbb{E}(N)$$

Dokaz: DV

Definicija: Kovariančna matrika vektorja X je

$$\operatorname{var}(X) = \begin{bmatrix} \operatorname{cov}(X_1, X_1) & \cdots & \operatorname{cov}(X_1, X_n) \\ \vdots & \ddots & \vdots \\ \operatorname{cov}(X_n, X_1) & \cdots & \operatorname{cov}(X_n, X_n) \end{bmatrix}$$

Kovariančna matrika med slučajnima vektorjema X, Y je

$$\operatorname{cov}(X, Y) = \begin{bmatrix} \operatorname{cov}(X_1, Y_1) & \cdots & \operatorname{cov}(X_1, X_n) \\ \vdots & \ddots & \vdots \\ \operatorname{cov}(X_n, Y_1) & \cdots & \operatorname{cov}(X_n, Y_n) \end{bmatrix}$$

Opazka 5.5: $\operatorname{Var}(X) = \operatorname{cov}(X, X)$

Trditev 5.6:

$$\operatorname{cov}(X,Y) = \mathbb{E}((X-\mathbb{E}(X))(Y-\mathbb{E}(Y))^T) =$$
$$= \mathbb{E}(XY^T) - \mathbb{E}(X)\mathbb{E}(Y)^T$$

Dokaz: $(X-\mathbb{E}(X))(Y-\mathbb{E}(Y))^T =: [M_{ij}]_{ij}$

$$M_{ij} = (X_i - E(X_i))(Y_j - E(Y_j))$$
$$\Rightarrow \mathbb{E}(M_{ij}) = \operatorname{cov}(X_i, Y_j)$$

$\blacksquare$

Posledica 5.7:

Kovariančna matrika poljubnega slučajnega vektorja je simetrična, saj je slučajna matrika $(X-\mathbb{E}(X))(Y-\mathbb{E}(Y))^T$ simetrična

Dokaz: $\square$

Opazka 5.8

- X, Y slučajna vektorja A, B deterministični matriki

velja: $\operatorname{cov}(AX, BY) = E\left((AX - E(AX))(BY - E(BY))^T\right) =$

$$= E\left(A(X - E(X))(Y - E(Y))^T B^T\right) =$$

$$A\, E\left((X - E(X))(Y - E(Y))^T\right) B^T =$$

$$= A \operatorname{cov}(X, Y) B^T$$

Posledično je tudi $\operatorname{var}(AX) = A \operatorname{var}(X) A^T$

- $0 \leq \operatorname{var}(\langle X, u \rangle) = \operatorname{var}(u^T X) = u^T \operatorname{var}(X) u =$

$$= \langle \operatorname{var}(X) u, u \rangle$$

Posledica 5.9: $\operatorname{var}(X)$ je pozitivno semidefinitna

Trditev 5.10

Dana matrika je kovariančna matrika nekega slučajnega vektorja $\Leftrightarrow$ ko je pozitivno semidefinitna

Dokaz: ($\Rightarrow$) Posledica 5.9

($\Leftarrow$) Označimo dano matriko Σ in naj bo velikosti $n \times n$.

Vzemimo $Z = \begin{bmatrix} Z_1 \\ \vdots \\ Z_n \end{bmatrix}$, kjer so $Z_1, \dots Z_n$ neodvisne in $Z_i \sim N(0,1)$. $Var(Z) = I_n$ seveda.

Oglejmo si slučajni vektor $X = AZ$.

Po opazki 5.8 je $var(X) = AA^T$.

Slučajni vektor X bo zadoščal zahtevi, brž ko bo $AA^T = \Sigma$.

Ustrezna matrika pa obstaja, ker je Σ pozitivnosemidefinitna (Cholesky

Posledica 5.11

Za $\forall \mu \in \mathbb{R}^n$ in $\forall$ pozitivno semidefinitno matriko $\Sigma \in \mathbb{R}^{n \times n}$, $\exists$ sluč. vekt. X z $E(X) = \mu$ in $Var(X) = \Sigma$

Opazka 5.12.

1) Za bločni slučajni vektor $X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ je
$$E(X) = \begin{bmatrix} E(X_1) \\ E(X_2) \end{bmatrix}$$

2) Za bločno slučajno matriko
$$M = \begin{bmatrix} M_{11} & M_{12} \\ M_{21} & M_{22} \end{bmatrix}, \text{ je } E(M) = \begin{bmatrix} E(M_{11}) & E(M_{12}) \\ E(M_{21}) & E(M_{22}) \end{bmatrix}$$

3) Za bločna slučajna vektorja
$$X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \text{ in } Y = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} \text{ je } cov(X,Y) = \begin{bmatrix} cov(X_1,Y_1) & cov(X_1,Y_2) \\ cov(X_2,Y_1) & cov(X_2,Y_2) \end{bmatrix}$$

Če sta X in Y enako velika: $var(X+Y) = ?$

$$X+Y = [I_n \; I_m] \begin{bmatrix} X \\ Y \end{bmatrix}$$ $\rightsquigarrow$ vsota lahko zapišemo z bloki

Opazka 5.13.

$$var(X+Y) = var\left([I_n \; I_n] \begin{bmatrix} X \\ Y \end{bmatrix}\right) =$$

$$= [I_n \; I_n] \; var\left(\begin{bmatrix} X \\ Y \end{bmatrix}\right) \begin{bmatrix} I_n \\ I_n \end{bmatrix} =$$

$$= [I_n \; I_n] \begin{bmatrix} var(X) & cov(X,Y) \\ cov(Y,X) & var(Y) \end{bmatrix} \begin{bmatrix} I_n \\ I_n \end{bmatrix} =$$

$$= var(X) + cov(X,Y) + cov(Y,X) + var(Y)$$

Trditev 5.14

$$\mathrm{cov}(Y,X) = (\mathrm{cov}(X,Y))^T$$

Dokaz: DN

Definicija: Slučajna vektorja X in Y sta nekorelirana, če je $\mathrm{cov}(X,Y)=0$

Opazka 5.15

Poljubna neodvisna slučajna vektorja sta nekorelirana, če le obstajata njuni pričakovani vrednosti

Posledica 5.16

Če sta slučajna vektorja X in Y enako velika in neodvisna, ter imata kovarianční matriki, velja: $\mathrm{var}(X+Y) = \mathrm{var}(X) + \mathrm{var}(Y)$

6. Pridobivanje cenilk

(logično nadaljevanje 4. poglavja)

6.1 Metoda empirične porazdelitve

Opazimo vrednosti $x_1, x_2, \dots, x_n$, ki so enako porazdeljene: predstavljajo vzorec neke porazdelitve. Preučevana količina y nas se izraža kot karakteristika te porazdelitve

$$y = g(\theta) = \mathrm{Char}_\theta(X_1) = \mathrm{Char}(\text{porazdelitev za } X_1)$$

parameter porazdelitve

Tipična primera:

1) $\mathrm{Char}_\theta(X_1) = E_\theta(X_1)$

2) $\mathrm{Char}_\theta(X_1) = \mathrm{var}_\theta(X_1)$

Cenilka za y je potem $\hat{y} = \mathrm{Char}(\mathrm{Emp}(x_1, \dots, x_n))$

1) $y = \mu = E_\theta(X_1)$: $\hat{y} = \hat{\mu} = \frac{x_1 + \dots + x_n}{n} = \bar{x}$

2) $y = \mathrm{var}_\theta(X_i)$: $\hat{y} = \frac{(x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n}$

Kako dobri sta ti dve cenilki?

1) $\bar{x}$ je nepristranska. Koliko je standardna napaka?

1.1) X_i nekorelirane, je $SE = \sqrt{var_y(\bar{x})} = \frac{\sigma}{n}$

1.2) enostavno slučajno vzorčenje:

Na populaciji z N enotami naj bo definirana statistična spremenljivka, katerej funkcija $[N] \to \mathbb{R}: i \mapsto X_i$

Iz populacije vzamemo vzorec, ki naj ga sestavljajo enote z indeksi $k_1, \dots, k_n \in [N]$. Le ti so izbrani naključno.

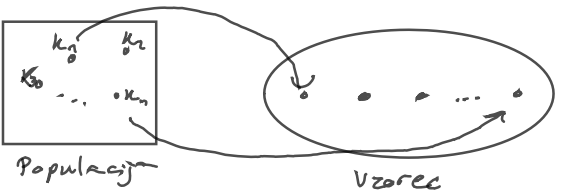

O enostavnem slučajnem vzorčenju govorimo, če so vsi možni vzorci brez ponavljanja enako verjetni, tj. če je slučajni vektor $(k_1, \dots, k_n)$ porazdeljen enakomerno na množici $\{k_1 \dots k_n;\ k_i \in [N],\ k_i \text{ vsi različni}\}$

$X_i = x_{k_i} \quad i \in [n]$

$var(\bar{X}) = ?$

$X_1, \dots, X_N \sim Emp(x_1, \dots, x_N)$

$$\mu := E(X_1) = \frac{x_1 + \dots + x_N}{N}$$

$$\sigma^2 := var(X_1) = \frac{(x_1-\mu)^2 + \dots + (x_n-\mu)^2}{N}$$

$$SE^2 = var(\bar{X}) \qquad SE^2 = var\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right)$$

$$= \frac{1}{n^2}\sum_{i,j} cov(X_i, X_j)$$

$i = j \Rightarrow cov(X_i, X_j) = \sigma$

$i \neq j \Rightarrow$

$$E(X_i X_j) = E(X_{k_i} X_{k_j}) =$$

$$= \sum_{k,l} x_k x_l \underbrace{\mathbb{P}(K_i = k, K_j = l)}_{\begin{cases} \frac{1}{N(N-1)} & ; k \neq l \\ 0 & ; k = l \end{cases}} =$$

$$= \sum_{k \neq l} x_k x_l \frac{1}{N(N-1)} =$$

$$= \frac{1}{N(N-1)} \sum_{k,l} x_k x_l - \frac{1}{N(N-1)} \sum_{k=1}^{N} x_k^2 =$$

$$= \frac{1}{N(N-1)} \left(\sum_{k=1}^{n} x_k\right)^2 - \frac{1}{N(N-1)} \sum x_k^2 =$$

$$= \frac{N}{N-1}\left(\frac{1}{N}\sum x_k\right)^2 - \frac{1}{N-1}\left(\frac{1}{N}\sum x_k^2\right) =$$

$$= \frac{N}{N-1} E(X_1)^2 - \frac{1}{N-1} E(X_1^2) =$$

$$- \frac{1}{N-1}\sigma^2 + N\mu$$

$$\Rightarrow cov(X_i, X_j) = \frac{-\sigma^2}{N-1} \qquad \text{za } i \neq j$$

Potem je $SE^2 = \frac{1}{n^2}\left(n\sigma^2 - n(n-1) \cdot \frac{1}{N-1}\sigma^2\right)$ za $i = j$

$$= \frac{\sigma^2}{n}\left(1 - \underbrace{\frac{n-1}{N-1}}_{\text{popravek za končne populacije (korekcijski člen)}}\right) = \frac{\sigma^2}{n}\underbrace{\left(\frac{N-n}{N-1}\right)}_{\text{korekcijski faktor}}$$

Opomba: Tudi pri enostavnem slučajnem vzorcu se izkaže, da je $\bar{X}$ NNLC za μ.

② Char = var

$$y = var(X_1) = \sigma^2$$

$$\hat{\sigma}^2 = \frac{(X_1-\bar{X})^2 + \dots (X_n-\bar{X})^2}{n}$$

Je ta cenilka nepristranska?

Koliko je torej $E(\hat{\sigma}^2)$?

$$\hat{\sigma} = \frac{1}{n}\left\|\begin{bmatrix} x_1-\bar{x} \\ \vdots \\ x_n-\bar{x}\end{bmatrix}\right\|^2 \qquad X = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \qquad 1_n := \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}$$

$$H = I_n - \frac{1}{n} 1_n 1_n^T$$

$$\bar{X} = \frac{1}{n} \cdot 1_n^T X$$

$$\hat{\sigma}^2 = \frac{1}{n}\left\| X - \frac{1}{n} 1_n 1_n^T X \right\|^2 = \frac{1}{n}\|HX\|^2 =$$

$$= \frac{1}{n}(HX)^T(HX) = \frac{1}{n} X^T H^T H X$$

Zaloga vrednosti matrike $1_n 1_n^T$?

$\frac{1}{n} 1_n (1_n^T X)$ ima vse komponente enake

$$X = \alpha 1_n : \quad \frac{1}{n} 1_n 1_n^T X = \alpha \frac{1}{n} 1_n \underbrace{(1_n^T 1_n)}_{n} = \alpha 1_n = X$$

$1_n 1_n^T$ je torej projektor na podprostor vektorjev, ki imajo vse komponente enake

$$\text{rang}\left(\frac{1}{n} 1_n 1_n^T\right) = 1$$

$$\left(\frac{1}{n} 1_T 1_n^T\right)^T = \frac{1}{n} 1_n 1_n^T$$

Gre torej za ortogonalni projektor.

Torej je tudi H ortogonalni projektor ranga $n-1$

$$\hat{\sigma}^2 = \frac{1}{n} X^T H X$$